

NLTK调研报告

任务要求

本次调研的基本任务如下：

基础任务：

1. 知道NLTK是啥，能做什么
2. 了解所有可能的用途，跑通部分测试用例

进阶任务：

1. 阅读代码，了解程序构造原理，类库结构
2. 分析背后的机器学习理论、方法和高效能编程最佳实践

NLTK 介绍

NLTK，全称Natural Language Toolkit，自然语言处理工具包，由宾夕法尼亚大学的Steven Bird和Edward Loper开发的模块。

NLTK是构建Python程序以使用人类语言数据的领先平台。它为50多种语料库和词汇资源（如WordNet）提供了易于使用的界面，还提供了一套用于分类，标记化，词干化，标记，解析和语义推理的文本处理库。

NLTK是Python上著名的自然语言处理库 自带语料库，具有词性分类库 自带分类，分词，等等功能。NLTK被称为“使用Python进行教学和计算语言学工作的绝佳工具”，以及“用自然语言进行游戏的神奇图书馆”。

来自NLTK官网 www.NLTK.org

NLTK 安装方法

安装方法：

```
pip install --user -U nltk
```

进入python后，使用nltk.download()根据弹出的界面自动下载需要的数据和package

```
import nltk
nltk.download()
```

NLTK功能分析

本部分主要参考的资料是NLTK的官方指导书



进行一个分类任务的简单流程可以参考仓库中的 [功能分析/simple.ipynb](#)

NLTK的主要模块和功能

下面两个表展示了NLTK包下的各个子包和子模块的功能和对应的自然语言处理任务（按照字典序排序）

对于NLTK包功能的详细分析聚焦于主要的自然语言处理任务

NLTK的子包	自然语言处理任务	功能
app	应用	图形化交互式NLTK工具
ccg	语义解析	组合范畴文法
chat	应用	聊天机器人
chunk	分块	使用正则表达式、n-gram、命名实体等方式进行分块
classify	分类任务	对文本进行分类（打标签）
cluster	聚类任务	K-means、EM、GAAC方法对文本进行聚类
corpus	访问语料库	通过该模块访问NLTK提供的语料库和词典
draw	应用	绘制NLTK的解析树
inference	语义解释	用于定理证明和模型检验
lm	语言模型	目前只包含n-gram模型
metrics	指标评估	对自然语言处理结果使用召回率等指标进行评估
parse	语法解析	使用图表或概率解析的方式生成语法树

NLTK的子包	自然语言处理任务	功能
sem	语义解释	使用一阶逻辑公式表示语义结构， 在集合理论模型中进行评估
sentiment	情感分析	使用NLTK内置特征和分类器对文本进行情感分析
stem	词干提取	抽取词的词干或词根形式
tag	词性标注	使用n-gram，backoff，HMM等算法进行词性标注
tbl	机器学习	基于转换的机器学习(Transformation Based)， 被BrillTagger使用
test	测试	NLTK内模块的单元测试
tokenize	词元化	将文本按照不同粒度划分
translate	机器翻译	用于机器翻译任务的特征
tree	文本结构	用于表示文本的语言结构，如语法树
twitter	应用	使用Twitter API检索Tweet文档

NLTK的子模块	功能
book	NLTK的指导书
cli	NLTK的命令行工具
collections	NLTK实现的collection
collocations	识别词组的工具
compat	版本兼容
data	查找和加载NLTK提供的资源
decorators	NLTK内置的decorator
downloader	NLTK语料库和模块下载器
featstruct	文本特征结构的基本数据类和对特征结构进行基本操作的类
grammar	表示上下文无关语法的基本数据类。
help	NLTK使用帮助

NLTK的子模块	功能
internals	NLTK内置的与java、字符串交互的工具
jsontags	给数据打上JSON标记，便于downloader查找文件
lazyimport	延迟模块导入，加速启动时间
probability	表示和处理概率信息的类
text	各种用于文本分析的功能：索引、正则表达式搜索等
tgrep	用Tgrep算法搜索NLTK中的树结构
toolbox	用于读取、写入和操作工具箱数据库和设置文件，处理SIL工具箱格式的数据
treeprettyprinter	对于NLTK中树结构的漂亮的绘制
treetransforms	解析自然语言中的语法转换的方法集合
util	一些实用方法
wsd	为上下文中的歧义单词返回一个同义词集

接下来按照自然语言处理的流程依次调研分析NLTK的功能

文本获取

获取某一自然语言处理任务需要的文本，NLTK提供了大量的语料库适用于不同的自然语言处理任务，并提供接口下载这些语料库。可以通过corpus模块去访问语料库，以对象的方式读取语料库内的文本和附加的处理（词性标注、标签等）。

corpus是nltk内置的语料库，可以通过corpus访问不同语言、不同类型的语料库，在这些语料库上进行自然语言处理任务。许多文本语料库包含语言学注释，POS标签、命名实体、句法结构、语义角色等等

```
import nltk
from nltk.corpus import gutenberg
gutenberg.fileids() # 语料库中的文件标识符
```

```
['austen-emma.txt',
 'austen-persuasion.txt',
 'austen-sense.txt',
 'bible-kjv.txt',
 'blake-poems.txt',
 'bryant-stories.txt',
 'burgess-busterbrown.txt',
 'carroll-alice.txt',
 'chesterton-ball.txt',
 'chesterton-brown.txt',
 'chesterton-thursday.txt',
 'edgeworth-parents.txt',
 'melville-moby_dick.txt',
 'milton-paradise.txt',
 'shakespeare-caesar.txt',
 'shakespeare-hamlet.txt',
 'shakespeare-macbeth.txt',
 'whitman-leaves.txt']
```

将语料库作为单词列表或者句子列表来访问，可以按照类别、文本名称等组织方式来读取语料库中的文本 NLTK的文本语料库按照不同的结构方式组织在一起：

- 独立的文本，文本之间没有组织起来
- 按照类别（类别之间不重叠）组织，如流派
- 重叠的类别组织，如主题类别
- 按照时间组织，如就职演讲语料库

```
from nltk.corpus import brown
categories = brown.categories()
news_text = brown.words(categories='news') # 通过category检索文本
fdist = nltk.FreqDist(w.lower() for w in news_text)
modals = ['can', 'could', 'may', 'might', 'must', 'will']
for m in modals:
    print(m + ":", fdist[m], end = ' ')
```

```
can: 94 could: 87 may: 93 might: 38 must: 53 will: 389
```

NLTK支持用户导入自己的文本 通过 `PlaintextCorpusReader` 直接导入文本，访问语料库 如果有 Penn Treebank 对象的本地拷贝，可以通过 `BracketParseCorpusReader` 访问语料库

NLTK提供的语料库的形式有：

- 单词列表

- 表格，每一行是单词和单词的属性
- 工具箱文件，工具箱文件由一组条目组成，其中每个条目由一个或多个字段组成

```
from nltk.corpus import stopwords # 停用词
stopwords.words('english') # 单词列表的示例
```

```
['i',
 'me',
 'my',
 'myself',
 'we',
 'our',
 'ours',
 'ourselves',
```

```
from nltk.corpus import cmudict # cmu发音词典，表格语料库的示例
print(len(cmudict.entries()))
for entry in cmudict.entries()[42371:42379]:
    print(entry)
```

```
133737
('fir', ['F', 'ER1'])
('fire', ['F', 'AY1', 'ER0'])
('fire', ['F', 'AY1', 'R'])
('firearm', ['F', 'AY1', 'ER0', 'AA2', 'R', 'M'])
('firearm', ['F', 'AY1', 'R', 'AA2', 'R', 'M'])
('firearms', ['F', 'AY1', 'ER0', 'AA2', 'R', 'M', 'Z'])
('firearms', ['F', 'AY1', 'R', 'AA2', 'R', 'M', 'Z'])
('fireball', ['F', 'AY1', 'ER0', 'B', 'AO2', 'L'])
```

```
from nltk.corpus import toolbox
toolbox.entries('rotokas.dic')[:5]
```

```
[('kaa',
  [('ps', 'V'),
   ('pt', 'A'),
   ('ge', 'gag'),
   ('tkp', 'nek i pas'),
   ('dcsv', 'true'),
   ('vx', 'l'),
   ('sc', '???'),
   ('dt', '29/Oct/2005'),
   ('ex', 'Apoka ira kaaroi aioa-ia reoreopaoro.'),
   ('xp', 'Kaikai i pas long nek bilong Apoka bikos em i kaikai na toktok.'),
   ('xe', 'Apoka is gagging from food while talking.')]),
 ,,
```

WordNet是面向语义的英语词典，NLTK提供了WordNet的语料库。使用WordNet可以查看单词的词义、同义词和反义词

```
# 使用WordNet可以查看单词的词义、同义词和反义词
from nltk.corpus import wordnet
print(wordnet.synsets('motorcar')) # 查看词义
print(wordnet.synset('car.n.01').lemma_names()) # 查看近义词
print(wordnet.synset('car.n.01').definition()) # 查看词的具体定义
```

```
[Synset('car.n.01')]
['car', 'auto', 'automobile', 'machine', 'motorcar']
a motor vehicle with four wheels; usually propelled by an internal combustion engine
```

WordNet同义词对应抽象的概念，它们在英语中并不总是有对应的单词。这些概念以层次结构连接在一起。

```
motorcar = wordnet.synset('car.n.01')
types_of_motorcar = motorcar.hypernym() # 查看car相关的概念
sorted(lemma.name() for synset in types_of_motorcar for lemma in synset.lemmas())
```

```
['Model_T',
 'S.U.V.',
 'SUV',
 'Stanley_Steamer',
 'subcompact']
```

```
paths = motorcar.hypernym_paths()
[synset.name() for synset in paths[0]] # 查看car在概念树中的路径
```

```
['entity.n.01',
 'physical_entity.n.01',
 'object.n.01',
 'whole.n.02',
 'artifact.n.01',
 'instrumentality.n.03',
 'container.n.01',
 'wheeled_vehicle.n.01',
 'self-propelled_vehicle.n.01',
 'motor_vehicle.n.01',
 'car.n.01']
```

WordNet中的概念树中词与词之间有比较复杂的关系：

- part词集包含这个词对应的事物的组成部分
- substance词集表示这个词对应事物的材质
- member词集则表示这个词对应事物的整体

```
print(wordnet.synset('tree.n.01').part_meronyms())
print(wordnet.synset('tree.n.01').substance_meronyms())
print(wordnet.synset('tree.n.01').member_holonyms())
```

```
[Synset('burl.n.02'), Synset('crown.n.07'), Synset('limb.n.02'), Synset('stump.n.01'), Synset('trunk.n.01')]
[Synset('heartwood.n.01'), Synset('sapwood.n.01')]
[Synset('forest.n.01')]
```

WordNet中的同义词网络，使得不同的词可能共享同一个同义词超集，可以找到两个词之间最近的概念超集来估量这两个词词义上的联系和区别。

```
right = wordnet.synset('right_whale.n.01')
minke = wordnet.synset('minke_whale.n.01')
tortoise = wordnet.synset('tortoise.n.01')
print(right.lowest_common_hypernyms(minke))
print(right.lowest_common_hypernyms(tortoise))
```

```
[Synset('baleen_whale.n.01')]
[Synset('vertebrate.n.01')]
```

因为同义词网络是概念上的逐步具体化和细化，可以利用词在层次网络结构中的深度表示这个词的具体性或者说一般性。

```
print(wordnet.synset('right_whale.n.01').min_depth())
print(wordnet.synset('minke_whale.n.01').min_depth())
print(wordnet.synset('tortoise.n.01').min_depth())
```

```
15
16
13
```

衡量两个词之间的相似度同样可以通过层次网络中的路径的相似度来衡量

```
print(right.path_similarity(minke))
print(right.path_similarity(tortoise))
```

```
0.25
0.07692307692307693
```

文本处理

获得文本后要对文本的格式等做一个规范化，将HTML等格式的文本转换为字符串形式，接下来要从文本中获取信息。

NLTK可以通过将文本转换为Text对象进行索引、查找等一系列操作

文本预处理旨在从文本中提取信息，将非结构化的文本转换为结构化的数据结构，信息提取的大致流程：

- 使用句子分割器将原始文本划分为句子
- 使用分词器（词元化方法）将句子划分为词
- 对每个词进行词性标注，打上标签
- 命名实体识别，识别已定义的实体（约定俗成的习语和专有名词）和未定义的实体
- 进行文本中实体间关系的识别，搜索邻近实体对之间的特定模式，建立实体之间的关系图

NLTK不支持对中文进行分句、分词、词性标注等预处理操作，推荐的库有jieba

文本分割

第一步是将文本划分为句子和分词的代码都在NLTK的tokenizer模块中实现

NLTK基于不同的算法实现tokenizer，包括分句器、多种分词器、还有一些特殊的tokenizer，并在基础分词器、分局器的基础上进行扩展。

分句

NLTK使用PunktSentenceTokenizer进行分句，这是一种使用无监督算法通过缩写词、固定搭配、标点符号和某些开始句子的固定的词进行训练的分句器。

```
import nltk
from nltk.corpus import state_union
from nltk.tokenize import PunktSentenceTokenizer

train_text = state_union.raw("2005-GWBush.txt")
sample_text = state_union.raw("2006-GWBush.txt")

custom_sent_tokenizer = PunktSentenceTokenizer(train_text)

tokenized = custom_sent_tokenizer.tokenize(sample_text)
print(tokenized[:2])
```

```
['PRESIDENT GEORGE W. BUSH'S ADDRESS BEFORE A JOINT SESSION OF THE CONGRESS ON THE STATE OF THE UNIO
N
January 31, 2006
THE PRESIDENT: Thank you all.', 'Mr. Speaker, Vice President Cheney, members of Congress, members of the Supreme Court and diplomatic corps, distinguished guests, and fellow citizens: Today our nation lost a beloved, graceful, courageous woman who called America to its founding ideals and carried on a noble dream.']
```

分词

NLTK中的基础分词器包括：

- RegexpTokenizer：使用正则表达式分词

- ReppTokenizer: Repp分词器 <http://anthology.aclweb.org/P/P12/P12-2.pdf#page=406>
- ToktokTokenizer: 通用分词器
- TreebankWordTokenizer: 使用正则表达式对文本进行标记之后分词

```
regex_tokenizer = nltk.tokenize.RegexpTokenizer('\w+|\$[\d\.]+\S+')
print(regex_tokenizer.tokenize(text)) # 简单的根据正则表达式分词
```

```
['Is', '9', '.5', 'or', '525', ',600', 'my', 'favorite', 'number', '?', 'May', 'I', 'help', 'you', '?']
```

```
toktok = nltk.tokenize.ToktokTokenizer() # TikTok通用分词器
text = u'Is 9.5 or 525,600 my favorite number?'
print(toktok.tokenize(text, return_str=False))
```

```
['Is', '9.5', 'or', '525,600', 'my', 'favorite', 'number', '?']
```

```
s = '''Good muffins cost $3.88\nin New York. Please buy me\ntwo of them.\nThanks.'''
print(nltk.tokenize.TreebankWordTokenizer().tokenize(s))
```

```
['Good', 'muffins', 'cost', '$', '3.88', 'in', 'New', 'York.', 'Please', 'buy', 'me', 'two', 'of', 'them.', 'Thanks', '.']
```

NLTK支持简单分词（按照空格分词）以及按照行/空格/制表符进行分词的简单分词器

```
text = """Is 9.5 or 525,600 my favorite number?
May I help you?
"""
print(nltk.tokenize.casual_tokenize(text))
print(nltk.tokenize.LineTokenizer().tokenize(text))
```

```
['Is', '9.5', 'or', '525,600', 'my', 'favorite', 'number', '?', 'May', 'I', 'help', 'you', '?']
['Is 9.5 or 525,600 my favorite number?', 'May I help you?']
```

NLTK中还包括一些功能特殊的分词器:

- SExprTokenizer: 将句子按照括号分割
- SyllableTokenizer: 将词按照音节划分
- TextTilingTokenizer: 将文本中的每一段划分到其对应的子主题

```
text = '(a (b c)) d e (f)'
print(nltk.tokenize.SExprTokenizer().tokenize(text)) # 按照括号分词
```

```
['(a (b c))', 'd', 'e', '(f)']
```

```
from nltk.tokenize import SyllableTokenizer
SSP = SyllableTokenizer()
SSP.tokenize("justification")
```

```
['jus', 'ti', 'fi', 'ca', 'tion']
```

```
from nltk.corpus import brown
import numpy
tt = nltk.tokenize.TextTilingTokenizer(demo_mode=True) # 将文档标记到对应的子主题
text = brown.raw()[:4000]
s, ss, d, b = tt.tokenize(text)
b
```

```
[0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0]
```

统计分析

对于处理好的文本，可以使用NLTK中Text对象实现文本搜索和索引功能

```

from nltk.book import text1, text2, text4

print(text1.concordance("monstrous")) # 搜索单词
print()

print(text2.similar("monstrous")) # 搜索近义词
print()

print(text2.common_contexts(["monstrous", "very"])) # 搜索相关上下文
text4.dispersion_plot(["citizens", "democracy", "freedom", "duties", "America"]) # 词汇分布表


```

Displaying 11 of 11 matches:

ong the former , one was of a most monstrous size This came towards us ,
 ON OF THE PSALMS . " Touching that monstrous bulk of the whale or ork we have r
 ll over with a heathenish array of monstrous clubs and spears . Some were thick
 d as you gazed , and wondered what monstrous cannibal and savage could ever hav
 that has survived the flood ; most monstrous and most mountainous ! That Himmal
 they might scout at Moby Dick as a monstrous fable , or still worse and more de
 th of Radney . ' " CHAPTER 55 Of the Monstrous Pictures of Whales . I shall ere l
 ing Scenes . In connexion with the monstrous pictures of whales , I am strongly
 ere to enter upon those still more monstrous stories of them which are to be fo
 ght have been rummaged out of this monstrous cabinet there is no telling . But
 of Whale - Bones ; for Whales of a monstrous size are oftentimes cast up dead u
 None

very so exceedingly heartily a as good great extremely remarkably
 sweet vast amazingly
 None

a_pretty am_glad a_lucky is_pretty be_glad
 None



NLTK可以根据文本中的词序列构建词频统计

- 使用FreqDist词频表查看词的频率分布
- ConditionalFreqDist条件词频表则可以为语料库的文本中的每个类别查看频率分布

```

all_words = []
for w in movie_reviews.words():
    all_words.append(w.lower())

fdist = nltk.FreqDist(all_words) # 构建词频表
print(fdist['disappointing']) # 某个单词出现的频率
print(fdist.N()) # 词频表中的词的数量
print(fdist.most_common(15)) # 出现频率最大的n个单词
print(fdist.max()) # 出现频率最大的单词
# fdist.tabulate() 频率分布表

```

```

88
1583820
[(',', 77717), ('the', 76529), ('.', 65876), ('a', 38106), ('and', 35576), ('of', 34123), ('to', 31937), ('"', 30585), ('is', 25195), ('in', 21822), ('s', 18513), ('"', 17612), ('it', 16107), ('that', 15924), ('-', 15595)]

```

```

cfd = nltk.ConditionalFreqDist(
    (genre, word)
    for genre in brown.categories()
    for word in brown.words(categories=genre)) # 条件词频表
genres = ['news', 'religion', 'hobbies', 'science_fiction', 'romance', 'humor']
modals = ['can', 'could', 'may', 'might', 'must', 'will']
cfd.conditions()

```

```

['adventure',
 'belles_lettres',
 'editorial',
 'fiction',

```

NLTK可以通过绘图和表格对文本的频率分布进行可视化

```

cfd.tabulate(conditions=genres, samples=modals) # 表格

```

	can	could	may	might	must	will
news	93	86	66	38	50	389
religion	82	59	78	12	54	71
hobbies	268	58	131	22	83	264
science_fiction	16	49	4	12	8	16
romance	74	193	11	51	45	43
humor	16	30	8	8	9	13

词性标注

对于token序列可以进行一系列的操作帮助进一步分析句子的结构和语义，提取文本的特征

基本的任务就是词性标注，按照token的含义、上下文内容和语法属性给token序列中每一个token打上标签（tag）

NLTK在tag模块中根据多种机器学习算法实现了多种Tagger

NLTK中最简单的Tagger是DefaultTagger，给每个词用相同的Tag标注，这种标记方法毫无疑问效果是最差的

```
tokens = word_tokenize("I do not like green eggs.")
default_tagger = nltk.DefaultTagger('NN')
default_tagger.tag(tokens)
```

```
[('I', 'NN'),
 ('do', 'NN'),
 ('not', 'NN'),
 ('like', 'NN'),
 ('green', 'NN'),
 ('eggs', 'NN'),
 ('.', 'NN')]
```

NLTK实现了正则表达式标注器Regular Expression Tagger，通过正则表达式进行模式匹配，对匹配特定模式的词标注上特定的Tag

```
patterns = [
    (r'.*ing$', 'VBG'),          # gerunds
    (r'.*ed$', 'VBD'),           # simple past
    (r'.*es$', 'VBZ'),           # 3rd singular present
    (r'.*ould$', 'MD'),          # modals
    (r'.*\'s$', 'NN$'),           # possessive nouns
    (r'.*s$', 'NNS'),            # plural nouns
    (r'^-?[0-9]+(\.[0-9]+)?$', 'CD'), # cardinal numbers
    (r'.*', 'NN')                # nouns (default)
]
```

```
regexp_tagger = nltk.RegexpTagger(patterns)
regexp_tagger.tag(tokens)
regexp_tagger.evaluate(brown_tag_sents)
```

```
/tmp/ipykernel_3640262/4086225084.py:14: DeprecationWarning:
  Function evaluate() has been deprecated. Use accuracy(gold)
  instead.
  regexp_tagger.evaluate(brown_tag_sents)
```

0.20186168625812995

Lookup Tagger是用文本中词频最高的若干个词的标记生成查找表，用这些信息去对文本进行标记，如果文本中的词不在查找表中，则使用默认标记。NLTK的实现为UnigramTagger。随着生成查找表的词语的数量增加，Lookup Tagger标注的准确率提高。

```
fd = nltk.FreqDist(brown.words(categories='news'))
cfd = nltk.ConditionalFreqDist(brown.tagged_words(categories='news'))
most_freq_words = fd.most_common(100)
likely_tags = dict((word, cfd[word].max()) for (word, _) in most_freq_words)
lookup_tagger = nltk.UnigramTagger(model=likely_tags, backoff=nltk.DefaultTagger('NN'))
lookup_tagger.evaluate(brown_tag_sents)
```

```
/tmp/ipykernel_3640262/2724458264.py:6: DeprecationWarning:
  Function evaluate() has been deprecated.  Use accuracy(gold)
  instead.
  lookup_tagger.evaluate(brown_tag_sents)
```

0.5817769556656125

UnigramTagger(一元标注器)的实现基于一种简单算法：对于每个token，分配最可能用于该特定token的标记，可以通过给部分词性标注的数据给UnigramTagger进行训练（上面其实就是用词频最高的若干词进行训练）

```
size = int(len(brown_tag_sents) * 0.9)
train_sents = brown_tag_sents[:size]
test_sents = brown_tag_sents[size:]
unigram_tagger = nltk.UnigramTagger(train_sents)
print("train accuracy:", unigram_tagger.evaluate(train_sents))
print("test accuracy:", unigram_tagger.evaluate(test_sents))
```

```
/tmp/ipykernel_3640262/2076228030.py:5: DeprecationWarning:
  Function evaluate() has been deprecated.  Use accuracy(gold)
  instead.
  print("train accuracy:", unigram_tagger.evaluate(train_sents))
train accuracy: 0.9353630649241612
test accuracy: 0.8121200039868434
```

N-Gram Tagging是Unigram Tagging的一般情况，通过前n个词的标记作为上下文来判断该词的标记。需要注意N-Gram碰到未出现的词、句的表现很糟糕（因为没有相对应的上下文）。当n变得很大时，每个上下文出现的次数都很少，数据比较稀疏，标记的准确率也会比较高，覆盖率比较低。这里用BigramTagger作为示例进行展示


```

brown_sents = brown.sents()
unseen_sent = brown_sents[4203]
bigram_tagger = nltk.BigramTagger(train_sents)

print(bigram_tagger.tag(brown_sents[2007]))
print(bigram_tagger.tag(unseen_sent))
print(bigram_tagger.evaluate(test_sents))

[('Various', 'JJ'), ('of', 'IN'), ('the', 'AT'), ('apartments', 'NNS'), ('are', 'BER'), ('of', 'IN'), ('the', 'AT'), ('terrace', 'NN'), ('type', 'NN'), ('', ''), ('being', 'BEG'), ('on', 'IN'), ('the', 'AT'), ('ground', 'NN'), ('floor', 'NN'), ('so', 'CS'), ('that', 'CS'), ('entrance', 'NN'), ('is', 'BEZ'), ('direct', 'JJ'), ('.', '.')]
[('The', 'AT'), ('population', 'NN'), ('of', 'IN'), ('the', 'AT'), ('Congo', 'NP'), ('is', 'BEZ'), ('13.5', None), ('million', None), ('', None), ('divided', None), ('into', None), ('at', None), ('1 east', None), ('seven', None), ('major', None), ('', None), ('culture', None), ('clusters', None), ('''', None), ('and', None), ('innumerable', None), ('tribes', None), ('speaking', None), ('400', None), ('separate', None), ('dialects', None), ('.', None)]
0.10206319146815508

```

NLTK可以将Tagger进行组合，准确性较强的Tagger进行一般的标记，当找不到词的标记时可以使用覆盖率更大的Tagger

```

t0 = nltk.DefaultTagger('NN')
t1 = nltk.UnigramTagger(train_sents, backoff=t0)
t2 = nltk.BigramTagger(train_sents, backoff=t1)
t2.evaluate(test_sents)

/tmp/ipykernel_3640262/2463049084.py:4: DeprecationWarning:
  Function evaluate() has been deprecated. Use accuracy(gold)
  instead.
  t2.evaluate(test_sents)

0.8452108043456593

```

CRFTagger根据条件随机场（CRF）算法进行词性标注的tagger

```

crf_tagger = nltk.CRFTagger()
crf_tagger.train(train_sents[:10], 'model.crf_tagger') # 因为训练时间过长简单演示一下
crf_tagger.evaluate(test_sents)

/tmp/ipykernel_3640262/2180368135.py:3: DeprecationWarning:
  Function evaluate() has been deprecated. Use accuracy(gold)
  instead.
  crf_tagger.evaluate(test_sents)

0.5103159573407754

```

PerceptronTagger根据感知器模型进行词性标注的tagger


```

perceptron_tagger = nltk.PerceptronTagger()
perceptron_tagger.train(train_sents[:10], 'model.crf.tagger')
perceptron_tagger.evaluate(test_sents)

```

```

/tmp/ipykernel_3640262/577130703.py:3: DeprecationWarning:
  Function evaluate() has been deprecated. Use accuracy(gold)
  instead.
perceptron_tagger.evaluate(test_sents)

```

0.8686335094189176

Brill Tagger基于转换进行词性标注。其总体思路非常简单：猜测每个词的标签，然后再回头修正错误。Brill Tagger基于正确标记的数据进行训练，通过维护一个转换修正规则的列表，错误的标记连续地转化为更正确的标记

```

from nltk.tbl import demo as brill_demo
brill_demo.demo() # 简单展示Brill Tagger的训练过程

```

```

Loading tagged data from treebank...
Read testing data (200 sents/5251 wds)
Read training data (800 sents/19933 wds)
Read baseline data (800 sents/19933 wds) [reused the training set]
Trained baseline tagger
  Accuracy on test set: 0.8358
Training tbl tagger...
TBL train (fast) (seqs: 800; tokens: 19933; tpls: 24; min score: 3; min acc: None)
Finding initial useful rules...
  Found 12799 useful rules.

```

B				
S	F	r	0	Score = Fixed - Broken
c	i	o	t	R Fixed = num tags changed incorrect -> correct
o	x	k	h	u Broken = num tags changed correct -> incorrect
r	e	e	e	l Other = num tags changed incorrect -> incorrect
e	d	n	r	e

23	23	0	0	POS->VBZ if Pos:PRP@[-2,-1]
18	19	1	0	NN->VB if Pos:-NONE-@[-2] & Pos:TO@[-1]
14	14	0	0	VBP->VB if Pos:MD@[-2,-1]
12	12	0	0	VBP->VB if Pos:TO@[-1]
11	11	0	0	VBD->VBN if Pos:VBD@[-1]
11	11	0	0	IN->WDT if Pos:-NONE-@[1] & Pos:VBP@[2]
10	11	1	0	VBN->VBD if Pos:PRP@[-1]
9	10	1	0	VBD->VBN if Pos:VBZ@[-1]

```

Trained tbl tagger in 2.33 seconds
  Accuracy on test set: 0.8564
Tagging the test data

```

词干提取和词性还原

词干提取和词性还原是将词标准化的过程，NLTK将这两部分集成在stem模块中

词性还原是基于词典，将单词的复杂形态转变为最基础的形态，NLTK采用的词典是WordNet

```
from nltk.stem import WordNetLemmatizer

lemmatizer = WordNetLemmatizer()
words = ['cars', 'men', 'running', 'ate', 'saddest', 'fancier']
pos_tags = ['n', 'n', 'v', 'v', 'a', 'a'] # 对应的词性

for i in range(len(words)):
    print(words[i]+'--'+pos_tags[i]+'-->' + lemmatizer.lemmatize(words[i], pos_tags[i]))
```

```
cars--n-->car
men--n-->men
running--v-->run
ate--v-->eat
saddest--a-->sad
fancier--a-->fancy
```

词干提取则是去除词语的词缀，获得词根。

NLTK根据不同的词干提取算法，实现了不同的Stemmer，通过示例展示其用法，比较词干提取的结果：

- ARLSTem：阿拉伯语词干提取
- ARLSTem2：阿拉伯语词干提取
- Cistem：德语词干提取
- ISRISTemmer：基于ISR I阿拉伯语词干分析器的词干提取算法
- LancasterStemmer：Lancaster算法，英文词干提取
- PorterStemmer：Porter算法，英文词干提取
- RegexpStemmer：正则表达式来识别词语的词缀
- RSLPStemmer：葡萄牙语词干提取
- SnowballStemmer：Snowball算法，支持多国语言

```

from nltk.stem import *
words = ['table', 'probably', 'wolves', 'playing', 'is',
         'dog', 'the', 'beaches', 'grounded', 'dreamt', 'envision']
stemmers = ['PORTER', 'LANCASTER', 'SNOWBALL']
stemmer_porter = PorterStemmer()
stemmer_lancaster = LancasterStemmer()
stemmer_snowball = SnowballStemmer('english')

formatted_row = '{:>16}' * (len(stemmers) + 1)
print('\n', formatted_row.format('WORD', *stemmers), '\n')
for word in words:
    stemmed_words = [stemmer_porter.stem(word),
                     stemmer_lancaster.stem(word), stemmer_snowball.stem(word)]
    print(formatted_row.format(word, *stemmed_words))

```

WORD	PORTER	LANCASTER	SNOWBALL
table	tabl	tabl	tabl
probably	probabl	prob	probabl
wolves	wolv	wolv	wolv
playing	play	play	play
is	is	is	is
dog	dog	dog	dog
the	the	the	the
beaches	beach	beach	beach
grounded	ground	ground	ground
dreamt	dreamt	dreamt	dreamt
envision	envis	envid	envis

```

# 正则表达式匹配, 比较死板
st = RegexpStemmer('ing$|s$|e$|able$', min=4)
print(st.stem('cars'))
print(st.stem('mass'))

```

```

car
mas

```

分块

基于token序列，可以对token序列进行分块(chunking)，如将组成名词短语、动词短语的词分在一起，对token序列进行命名实体识别任务等。

分块是NLP中进行实体检测的基本技术，对多词序列进行分段和标记，将共同表示某个含义的词分割在一起形成一个单元，NLTK在chunk模块中实现了分块的功能。

对于chunking而言，最有效的信息依据是词的pos tag。最简单的分块方法是自己定义一个模式，使用正则匹配的方法对词序列进行匹配，匹配该模式的词序列划分为一个块。下面是根据pos tag划分名字短语的示例，分块的结果将识别到的NP用()划分在一起

```

sentence = [("the", "DT"), ("little", "JJ"), ("yellow", "JJ"), ("dog", "NN"), ("barked", "VBD"), ("at", "IN"), ("the", "DT"), ("cat", "NN")]

grammar = r"""
NP: {
    ?*}

    {+}
"""
cp = nltk.RegexpParser(grammar) # 正则分块器
result = cp.parse(sentence)
print(result)

```

```

(S
  (NP the/DT little/JJ yellow/JJ dog/NN)
  barked/VBD
  at/IN
  (NP the/DT cat/NN))

```

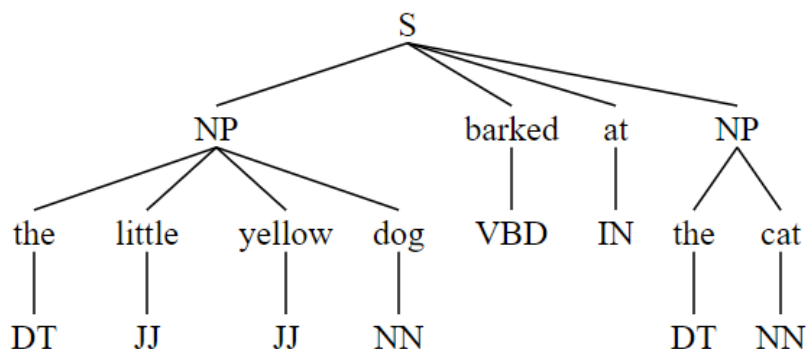
Chinking方法将满足条件的token序列从块中删除从而进行分块（以删除的方式进行分块而不是划分的方式）。简单的示例如下，下面的分块方法里匹配第一个模式的token序列会作为一个NP，匹配第二个模式的token序列会被删除

```

grammar = r"""
NP:
    {<.*>+}          # Chunk everything
    }+{               # Chink sequences of VBD and IN
"""

sentence = [("the", "DT"), ("little", "JJ"), ("yellow", "JJ"),
            ("dog", "NN"), ("barked", "VBD"), ("at", "IN"), ("the", "DT"), ("cat", "NN")]
cp = nltk.RegexpParser(grammar)
cp.parse(sentence)

```



NLTK可以对分块器的分块结果进行评估，可以对分块结果的Precision，Recall，F_Meature进行评估，IOB Accuracy表示IOB准确率，可以认为是分块准确率

```

from nltk.corpus import conll2000
test_sents = conll2000.chunked_sents('test.txt', chunk_types=['NP'])
grammar = r"NP: {<[CDJNP].*>+}"
cp = nltk.RegexpParser(grammar)
print(cp.evaluate(test_sents))

```

```

/tmp/ipykernel_3639522/4186991492.py:5: DeprecationWarning:
Function evaluate() has been deprecated. Use accuracy(gold)
instead.
print(cp.evaluate(test_sents))

```

```

ChunkParse score:
IOB Accuracy: 87.7%%
Precision: 70.6%%
Recall: 67.8%%
F-Measure: 69.2%%

```

通过扩展ChunkParserI接口，可以设计自己的分块器。下面通过Unigram的tag，根据Unigram的词性标注结果进行分块 可以将Unigram扩展到Bigram和N-gram

```

class UnigramChunker(nltk.ChunkParserI):
    def __init__(self, train_sents):
        train_data = [[(t, c) for w, t, c in nltk.chunk.tree2conlltags(sent)]
                       for sent in train_sents]
        self.tagger = nltk.UnigramTagger(train_data)

    def parse(self, sentence):
        pos_tags = [pos for (word, pos) in sentence]
        tagged_pos_tags = self.tagger.tag(pos_tags)
        chunktags = [chunktag for (pos, chunktag) in tagged_pos_tags]
        conlltags = [(word, pos, chunktag) for ((word, pos), chunktag)
                     in zip(sentence, chunktags)]
        return nltk.chunk.conlltags2tree(conlltags)

```

句子中token词性的标注无法完全决定句子分块的方式，需要将词的语义内容也作为分块的依据之一，基于这种方式可以使用基于分类器的tagger对句子进行分块 代码示例如下：

```

class ConsecutiveNPChunkTagger(nltk.TaggerI):
    def __init__(self, train_sents):
        train_set = []
        for tagged_sent in train_sents:
            untagged_sent = nltk.tag.untag(tagged_sent)
            history = []
            for i, (word, tag) in enumerate(tagged_sent):
                featureset = npchunk_features(untagged_sent, i, history)
                train_set.append( (featureset, tag) )
                history.append(tag)
            self.classifier = nltk.NaiveBayesClassifier.train(train_set)

    def tag(self, sentence):
        """对词的tag包含词性标记和分类结果（词义信息）"""
        history = []
        for i, word in enumerate(sentence):
            featureset = npchunk_features(sentence, i, history)
            tag = self.classifier.classify(featureset)
            history.append(tag)
        return zip(sentence, history)

class ConsecutiveNPChunker(nltk.ChunkParserI):
    def __init__(self, train_sents):
        tagged_sents = [[((w,t),c) for (w,t,c) in
                           nltk.chunk.tree2conlltags(sent)]
                          for sent in train_sents]
        self.tagger = ConsecutiveNPChunkTagger(tagged_sents)

    def parse(self, sentence):
        tagged_sents = self.tagger.tag(sentence)
        conlltags = [(w,t,c) for ((w,t),c) in tagged_sents]
        return nltk.chunk.conlltags2tree(conlltags)

```

命名实体是指特定类型的名词短语，如组织、个人、日期等。命名实体识别要识别文本中的所有命名实体，是一种特殊的分块任务：

- 识别命名实体的边界
- 识别命名实体的类型

命名实体识别适用于基于分类器的方法，根据词性标记和词义信息进行命名实体识别。NLTK提供了内置的命名实体识别器ne_chunk进行命名实体识别，其中binary参数为True将命名实体标记为NE，否则添加类别标签。

```

sent = nltk.corpus.treebank.tagged_sents()[22]
print(nltk.ne_chunk(sent, binary=True))
print(nltk.ne_chunk(sent, binary=False))

```

```

(S
  The/DT
  (NE U. S. /NNP)
  is/VBZ
  one/CD
  of/IN
  the/DT
  few/JJ
  industrialized/VBN
  nations/NNs
  that/WD
  *T*-7/-NONE-
  does/VBZ
  n' t/RB

```

命名实体关系的识别可以通过模式匹配，即识别满足特定模式的两个命名实体 如A in B就是一个可行的模式，体现了两个命名实体之间的包含关系。以下是使用NLTK进行命名实体关系识别的示例，通过nltk.sem.extract_rels识别文本中命名实体之间的关系，通过nltk.sem.rtuple提取元组进行输出

```
import re
IN = re.compile(r'.*\bin\b(?:\b.+ing)')
for doc in nltk.corpus.ieer.parsed_docs('NYT_19980315'):
    for rel in nltk.sem.extract_rels('ORG', 'LOC', doc, corpus='ieer', pattern=IN):
        print(nltk.sem.rtuple(rel))
```

```
[ORG: 'WHYY'] 'in' [LOC: 'Philadelphia']
[ORG: 'McGlashan & Sarrail'] 'firm in' [LOC: 'San Mateo']
[ORG: 'Freedom Forum'] 'in' [LOC: 'Arlington']
[ORG: 'Brookings Institution'] ', the research group in' [LOC: 'Washington']
```

句法分析

句法分析分析句子的句法结构（主谓宾结构）和词汇间的依存关系，从而为语义分析、情感分析等自然语言任务打基础。

NLTK在Parser模块中实现句法分析的功能，可以将句子转变为语法树，展示句子的语法结构

NLTK中可以自行定义上下文无关文法解析句子的结构，NLTK根据上下文无关文法的定义生成parser对句子进行解析，生成若干棵树表示根据文法解析出的不同的结构。在下文的示例中使用上下文无关文法进行语法分析时发现例句有两种不同的结构，代表其可能有两种不同的意思

NLTK中可以自行定义上下文无关文法解析句子的结构，NLTK根据上下文无关文法的定义生成parser对句子进行解析，生成若干棵树表示根据文法解析出的不同的结构 在下文的示例中使用上下文无关文法进行语法分析时发现例句有两种不同的结构，代表其可能有两种不同的意思

```
groucho_grammar = nltk.CFG.fromstring("""
S -> NP VP
PP -> P NP
NP -> Det N | Det N PP | 'I'
VP -> V NP | VP PP
Det -> 'an' | 'my'
N -> 'elephant' | 'pajamas'
V -> 'shot'
P -> 'in'
""")
sent = ['I', 'shot', 'an', 'elephant', 'in', 'my', 'pajamas']
parser = nltk.ChartParser(groucho_grammar) # 基于图的句法分析器
for tree in parser.parse(sent):
    print(tree)
```

```
(S
  (NP I)
  (VP
    (VP (V shot) (NP (Det an) (N elephant)))
    (PP (P in) (NP (Det my) (N pajamas)))))
(S
  (NP I)
  (VP
    (V shot)
    (NP (Det an) (N elephant) (PP (P in) (NP (Det my) (N pajamas))))))
```

使用上下文无关文法对句子进行解析时，NLTK内置了不同的解析算法：

- 递归向下分析：Recursive Descent Parsing
- 移进-归约分析：Shift-Reduce Parsing

```
In [3]: # 递归向下分析
grammar1 = nltk.CFG.fromstring("""
S -> NP VP
VP -> V NP | V NP PP
PP -> P NP
V -> "saw" | "ate" | "walked"
NP -> "John" | "Mary" | "Bob" | Det N | Det N PP
Det -> "a" | "an" | "the" | "my"
N -> "man" | "dog" | "cat" | "telescope" | "park"
P -> "in" | "on" | "by" | "with"
""")
rd_parser = nltk.RecursiveDescentParser(grammar1)
sent = 'Mary saw a dog'.split()
for tree in rd_parser.parse(sent):
    print(tree)
```

```
(S (NP Mary) (VP (V saw) (NP (Det a) (N dog))))
```

```
In [4]: # 移进-归约分析
sr_parser = nltk.ShiftReduceParser(grammar1)
for tree in sr_parser.parse(sent):
    print(tree)
```

```
(S (NP Mary) (VP (V saw) (NP (Det a) (N dog))))
```

同时NLTK还支持扩展的上下文无关文法，需要注意不同的上下文无关文法需要使用对应的parser

- 依存关系和依存文法 Dependencies and Dependency Grammar，关注词和词之间的关系
- 概率上下文无关文法 Probabilistic Context Free Grammar，分析树中引入了概率，返回概率最大的解析

```
In [5]: # 依存文法定义
groucho_dep_grammar = nltk.DependencyGrammar.fromstring("""
'shot' -> 'I' | 'elephant' | 'in'
'elephant' -> 'an' | 'in'
'in' -> 'pajamas'
'pajamas' -> 'my'
""")
print(groucho_dep_grammar)
# 依存文法解析器
pd_parser = nltk.ProjectiveDependencyParser(groucho_dep_grammar)
sent = 'I shot an elephant in my pajamas'.split()
for tree in pd_parser.parse(sent):
    print(tree)
```

```
Dependency grammar with 7 productions
```

```
'shot' -> 'I'
'shot' -> 'elephant'
'shot' -> 'in'
'elephant' -> 'an'
'elephant' -> 'in'
'in' -> 'pajamas'
'pajamas' -> 'my'
```

```
(shot I (elephant an (in (pajamas my))))
(shot I (elephant an) (in (pajamas my)))
```



```
In [6]: # 概率上下文无关文法
pcdg_grammar = nltk.PCFG.fromstring("""
S -> NP VP [1.0]
VP -> TV NP [0.4]
VP -> IV [0.3]
VP -> DatV NP NP [0.3]
TV -> 'saw' [1.0]
IV -> 'ate' [1.0]
DatV -> 'gave' [1.0]
NP -> 'telescopes' [0.8]
NP -> 'Jack' [0.2]
""")
print(pcdg_grammar)
# viterbi解析器
viterbi_parser = nltk.ViterbiParser(pcdg_grammar)
for tree in viterbi_parser.parse(['Jack', 'saw', 'telescopes']):
    print(tree)
```

```
Grammar with 9 productions (start state = S)
S -> NP VP [1.0]
VP -> TV NP [0.4]
VP -> IV [0.3]
VP -> DatV NP NP [0.3]
TV -> 'saw' [1.0]
IV -> 'ate' [1.0]
DatV -> 'gave' [1.0]
NP -> 'telescopes' [0.8]
NP -> 'Jack' [0.2]
(S (NP Jack) (VP (TV saw) (NP telescopes))) (p=0.064)
```

NLTK实现的基础句法解析器包括ChartParser, CoreNLPParser, MaltParser, ProbabilisticNonprojectiveParser, RecursiveDescentParser, ShiftReduceParser

NLTK基于这些基础的句法解析器实现多种更高效、更准确的句法解析器，因为数量太多而不一一列举

```
In [7]: # 递归向下分析
grammar1 = nltk.CFG.fromstring("""
S -> NP VP
VP -> V NP | V NP PP
PP -> P NP
V -> "saw" | "ate" | "walked"
NP -> "John" | "Mary" | "Bob" | Det N | Det N PP
Det -> "a" | "an" | "the" | "my"
N -> "man" | "dog" | "cat" | "telescope" | "park"
P -> "in" | "on" | "by" | "with"
""")
chart_parser = nltk.ChartParser(grammar1)
sent = 'Mary saw a dog'.split()
for tree in chart_parser.parse(sent):
    print(tree)
```

```
(S (NP Mary) (VP (V saw) (NP (Det a) (N dog))))
```

NLTK支持创建自定义的特征结构并对其进行操作

```
In [10]: fsl = nltk.FeatStruct(PER=3, NUM='pl', GND='01 23 86') # FeatStruct是nltk的特征结构类
print(fsl)

[ GND = '01 23 86' ]
[ NUM = 'pl' ]
[ PER = 3 ]
```

语义分析

自然语言处理中对句子进行语义分析，分为两部分：

词汇级

词汇级语义分析：对词的含义进行分析，主要是消除词在句子中的歧义，找到词在句中最合适的语义

关于词汇的含义，NLTK提供了WordNet语料库，该语料库包含了词汇的含义，在含义层面上对词与词之间的关系使用层级结构进行表示，可以参照上文的获取语料部分。

句子级

句子级语义分析：对于句子整体的含义进行分析

NLTK中对于句子可以通过命题逻辑分析其语义，对其进行验证和推理

对语句含义的理解可以考虑通过语法将其转换为计算机更容易理解的语言，NLTK内置了很多文法进行语言的简单翻译。如下边的示例根据NLTK中内置的文法，将自然语言转换为SQL语句

```
In [3]: from nltk import load_parser
cp = load_parser('grammars/book_grammars/sql0.fcfg')
query = 'What cities are located in China'
trees = list(cp.parse(query.split()))
answer = trees[0].label()['SEM']
answer = [s for s in answer if s]
q = ' '.join(answer)
print(q)
```

SELECT City FROM city_table WHERE Country="china"

NLTK可以将语言用逻辑语言进行表达，通过命题逻辑推理语言的含义。NLTK用命题逻辑表示语言结构中和特定句子连接词相对应的部分。

NLTK可以将逻辑表达式转换为Expression对象，通过NLTK的推理模块对Expression进行逻辑证明。

Expression对象提供了satisfiers方法，返回满足公式的所有个体的合集，可以判断某个集合内的变量中满足公式成立条件的变量有哪些

```
In [6]: from nltk.inference import Prover9

# nltk中的Expression对象能够将逻辑表达式，处理成Expression的子类。
read_expr = nltk.sem.Expression.fromstring
result = read_expr('-(P & Q)')
print(result)

# 逻辑证明通过nltk的推理模块进行。例如通过第三方定理证明程序prover9的接口。
# 并且推理机制的输入必须首先转换为逻辑表达式
# 这里因为Prover9安装困难就不演示了
SnF = read_expr('SnF')
NotFns = read_expr('¬FnS')
R = read_expr('SnF -> ¬FnS')
# prover = Prover9()
# result = prover.prove(NotFns, [SnF, R])
# print(result) True
```

-(P & Q)

```
In [11]: dom = {'b', 'o', 'c'}
g = nltk.Assignment(dom, [('x', 'o'), ('y', 'c')])
read_expr = nltk.sem.Expression.fromstring
fmla = read_expr('girl(x)|boy(x)')
result = m.satisfiers(fmla, 'x', g)
print(result) # {'b', 'o'}

# A->B可以等价于-A/B
fmla = read_expr('girl(x)->walk(x)')
result = m.satisfiers(fmla, 'x', g)
print(result) # {'c', 'o', 'b'}

# 全称量化公式。判断g中是否所有成员都满足
result = m.evaluate('all x. (girl(x) -> walk(x))', g)
print(result) # True

{'o', 'b'}
{'o', 'b', 'c'}
True
```

NLTK通过Valuation对象来确定逻辑表达式的真值

```
In [7]: # Valuation : 从逻辑的基本符号映射到他们的值。
val = nltk.Valuation([('P', True), ('Q', True), ('R', False)])
dom = set()
g = nltk.Assignment(dom)
# 用val初始化模型m
m = nltk.Model(dom, val)
# 使用evaluate()可确定逻辑表达式的真值情况
result = m.evaluate(' (P & Q)', g)
print(result)
```

True

NLTK可以通过将自然语言表达式转换为一阶逻辑来表达语句的含义 一阶逻辑保留命题逻辑的所有布尔运算，将识别命题中的谓词和参数进行分析 一阶逻辑表达式的语法结构通常是表达式分配类型：实体类型和公式类型 一阶逻辑也可以通过Prover9进行逻辑证明 以下是代码示例

```
In [8]: read_expr = nltk.sem.Expression.fromstring
expr = read_expr('walk(angus)', type_check=True)
print(expr.argument) # 参数
print(expr.argument.type) # 实体类型
print(expr.function) # 谓词
print(expr.function.type) # 公式类型

# 对一阶逻辑进行逻辑证明
NotFnS = read_expr('¬north_of(f, s)')
SnF = read_expr('north_of(s, f)')
R = read_expr('all x. all y. (north_of(x, y) -> ¬north_of(y, x))')
# prover = nltk.Prover9()
# prover.prove(NotFnS, [SnF, R]) # True

angus
e
walk
```

基于上述对象和方法，NLTK就可以通过一阶逻辑对句子进行语义分析，如判断某个句子是否有歧义

```
In [12]:
v = """
    bruce => b
    elspeth => e
    julia => j
    matthew => m
    person => {b, e, j, m}
    admire => {(j, b), (b, b), (m, e), (e, m)}
    """

val = nltk.Valuation.fromstring(v)

read_expr = nltk.sem.Expression.fromstring
dom = val.domain
m = nltk.Model(dom, val)
g = nltk.Assignment(dom)
fmla = read_expr('(person(x) -> exists y.(person(y) & admire(x, y)))')
result = m.satisfiers(fmla, 'x', g)
print(result)    # {'e', 'j', 'm', 'b'}

fmla = read_expr('(person(y) & all x.(person(x) -> admire(x, y)))')
result = m.satisfiers(fmla, 'y', g)
print(result)

{'m', 'e', 'b', 'j'}
set()
```

分类

基于上述对自然语言文本的分析，可以从文本中提取特征从而对文本进行分类，如情感分析等

```
In [1]:
import random
import nltk
from nltk.corpus import movie_reviews
documents = [(list(movie_reviews.words(fileid)), category)
              for category in movie_reviews.categories()
              for fileid in movie_reviews.fileids(category)]
random.shuffle(documents) # 读取文本并打乱，减小过拟合，让训练集和测试集的分布相近

In [3]:
all_words = nltk.FreqDist(w.lower() for w in movie_reviews.words())
word_features = list(all_words)[:2000]

def document_features(document):
    """特征工程"""
    document_words = set(document)
    features = {}
    for word in word_features:
        features['contains({})'.format(word)] = (word in document_words)
    return features

In [11]:
featuresets = [(document_features(d), c) for (d, c) in documents] # 注意NLTK特征集的形式为 (feature dict, label)
train_set, test_set = featuresets[100:], featuresets[:100]
# 使用朴素贝叶斯算法进行分类
classifier = nltk.NaiveBayesClassifier.train(train_set)
```

NLTK中提供了多种度量指标来对分类器的分类结果进行度量

```
In [21]:
print("accuracy:", nltk.classify.accuracy(classifier, test_set)) # 查看测试集上的准确率
print(nltk.ConfusionMatrix(test_predict, test_labels)) # 混淆矩阵
classifier.show_most_informative_features(5) # 最有效的五个特征

accuracy: 0.78
|  n  p  |
|  e  o  |
|  g  s  |
-----+-----
neg |<39>13|
pos | 9<39>|
-----+-----
(row = reference; col = test)

Most Informative Features
contains(miscast) = True          neg : pos    =      8.2 : 1.0
contains(unimaginative) = True    neg : pos    =      7.6 : 1.0
contains(shoddy) = True           neg : pos    =      7.0 : 1.0
contains(sexist) = True            neg : pos    =      7.0 : 1.0
contains(atrocious) = True         neg : pos    =      7.0 : 1.0
```

NLTK在classifier模块中根据多种机器学习算法实现了不同的Classifier

下面展示决策树、朴素贝叶斯、最大熵分类器三种经典的机器学习中的分类器

```
In [22]: decision_tree_classifier = nltk.classify.decisiontree.DecisionTreeClassifier.train(train_set) # 决策树
print("decision tree accuracy:", nltk.classify.accuracy(decision_tree_classifier, test_set)) # 查看测试集上的准确率

decision tree accuracy: 0.6
```

```
In [24]: max_entropy_classifier = nltk.classify.maxent.MaxentClassifier.train(train_set) # 决策树
print("max entropy accuracy:", nltk.classify.accuracy(max_entropy_classifier, test_set)) # 查看测试集上的准确率

==> Training (100 iterations)

  Iteration   Log Likelihood   Accuracy
-----
      1         -0.69315         0.499
D:\Anaconda\lib\site-packages\nltk\classify\maxent.py:1328: RuntimeWarning: overflow encountered in power
  exp_nf_delta = 2 ** nf_delta
D:\Anaconda\lib\site-packages\nltk\classify\maxent.py:1330: RuntimeWarning: invalid value encountered in multiply
  sum1 = numpy.sum(exp_nf_delta * A, axis=0)
D:\Anaconda\lib\site-packages\nltk\classify\maxent.py:1331: RuntimeWarning: invalid value encountered in multiply
  sum2 = numpy.sum(nf_exp_nf_delta * A, axis=0)
D:\Anaconda\lib\site-packages\nltk\classify\maxent.py:1338: RuntimeWarning: invalid value encountered in true_divide
  deltas -= (ffreq_empirical - sum1) / ~sum2
      Final           nan         0.499
max entropy accuracy: 0.52
```

Scikit-Learn库是Python中的机器学习库，提供了大量的机器学习算法，NLTK中可以通过SklearnClassifier使用sklearn模块的分类器

```
In [25]: from nltk.classify.skitlearn import SklearnClassifier
from sklearn.naive_bayes import MultinomialNB

MNB_classifier = SklearnClassifier(MultinomialNB())
MNB_classifier.train(train_set)
print("MultinomialNB accuracy:", nltk.classify.accuracy(MNB_classifier, test_set))

MultinomialNB accuracy: 0.78
```

聚类

NLTK实现了多种算法对文本进行聚类，将多个文本以无监督的方式分为不同的类

NLTK实现了三种常见的聚类方法：

- KMeans (K均值)
- 混合高斯聚类 (EM)
- GAAC (凝聚层次聚类法)

这里需要注意 聚类器传入数据的要求是numpy的array类型

这里使用三种聚类器对NLTK内置语料库中的电影评论进行聚类

```
In [8]: import nltk
from numpy import array
from nltk.cluster import *

datas = [array(v) for v in [(1, 0), (0, 1), (1, 1), (5, 5), (5, 4), (4, 5)]];

kmeans_clus = KMeansClusterer(2, euclidean_distance) #分为两类，距离函数用欧拉距离
kmeans_clus.cluster(datas, True, trace=False)
print([str(kmeans_clus.classify(data)) for data in datas])

['0', '0', '0', '1', '1', '1']
```

```
In [12]: em_clus = EMClusterer(initial_means=[[4, 2], [2, 1]])
em_clus.cluster(vectors = datas)
print([str(em_clus.classify(data)) for data in datas[:10]])
```

```
['1', '1', '1', '0', '0', '0']
```

```
In [9]: gaac_clus = GAAClusterer(num_clusters=2, normalise=True)
gaac_clus.cluster(vectors=datas)
gaac_clus.dendrogram().show()
print([str(gaac_clus.classify(data)) for data in datas])
```

```
['1', '0', '1', '1', '1', '1']
```